Universidad de Las Américas

FACULTAD DE INGENIERÍA Y CIENCIAS APLICADAS

INGENIERÍA DE SOFTWARE / SISTEMAS DE INFORMACIÓN

APRENDIZAJE AUTOMÁTICO

Código: IIAR0004 | **NRC:** 5414 | **Período:** Semestre 2026 – 2027 (2027-10)

EXAMEN DE APLICACIÓN PRÁCTICA – PROGRESO 1

Examen de Aplicación: Diagnóstico, Limpieza y Preparación de Datos Empresariales

Prevención de Fuga de Información, Pipeline Escalonado Scikit-Learn y Consideraciones Éticas en la Predicción de Abandono Financiero

Grupo Asignado:	Group 4 (Entrega Individual)
Estudiante / Autor:	**Carlos Alberto Angulo Pizarro** (carlos.angulo.pizarro@udla.edu.ec)
Docente Titular:	Raúl Paredes, M. Sc.
Fecha de Entrega:	Quito, 21 de octubre de 2026
Repositorio GitHub:	github.com/Elnuget/examen-progreso-1...
Google Colab Online:	Clic para abrir y ejecutar en Google Colab

QUITO – ECUADOR

1 Sección A: Fundamentos Conceptuales de Aprendizaje Automático

1.1 Definición del Problema de Negocio y Variable Objetivo

El problema planteado por la entidad financiera corresponde a la **retención de clientes** y la mitigación del **abandono (*Customer Churn*)**. El objetivo analítico consiste en identificar de forma anticipada los factores conductuales, demográficos y transaccionales asociados con la deserción de clientes, con la finalidad de desplegar estrategias proactivas y personalizadas de fidelización antes de que se formalice la cancelación del servicio.

* **Variable Objetivo (y):** Se define formalmente como la variable binaria indicadora abandono $\in \{0, 1\}$, donde:

$$y_i = \begin{cases} 1, & \text{si el cliente } i \text{ abandonó o canceló los servicios de la entidad financiera.} \\ 0, & \text{si el cliente } i \text{ permanece activo y fidelizado.} \end{cases} \quad (1)$$

1.2 Tipología de Aprendizaje: Supervisado

El problema se aborda estrictamente bajo el paradigma de **Aprendizaje Supervisado (*Supervised Learning*)**. La justificación técnica radica en que el conjunto de datos histórico dispone de una variable de salida explícita y rotulada (abandono $\in \{0, 1\}$) para cada registro observacional $\mathbf{x}_i$, la cual funge como señal supervisora durante la optimización matemática del algoritmo.

1.3 Naturaleza de la Tarea Futura: Clasificación Binaria

La tarea algorítmica corresponde a **Clasificación Binaria**, dado que el espacio de salida $\mathcal{Y}$ es cualitativo, discreto y dicotómico ($\mathcal{Y} = \{0, 1\}$). No se modela una variable de respuesta continua (regresión), sino la frontera de decisión bayesiana que separa ambas clases y la probabilidad posterior $P(Y = 1 \mid \mathbf{X} = \mathbf{x})$.

1.4 Ciclo de Vida de ML y Posición de la Preparación de Datos

El ciclo de ingeniería de soluciones de aprendizaje automático comprende:

1. **Comprensión del Negocio:** Planteamiento de hipótesis, métricas y restricciones.
2. **Auditoría y Exploración de Datos (EDA):** Perfilado y diagnóstico de integridad.
3. **Preparación y Preprocesamiento de Datos (Fase Actual):** Limpieza, imputación, ingeniería de características, codificación y escalamiento. Se ubica como el

puente crítico entre la recolección cruda y el modelado, consumiendo más del 70 % del esfuerzo técnico.

4. **Modelado Predictivo:** Ajuste algorítmico y búsqueda de hiperparámetros.
5. **Evaluación Rigurosa:** Medición sobre particiones independientes y auditoría de equidad.
6. **Despliegue y Monitoreo:** Puesta en producción y supervisión de *data drift*.

1.5 Peligro de Evaluar con los Mismos Datos de Entrenamiento

Evaluar un modelo predictivo sobre la misma muestra utilizada para ajustar sus parámetros genera una estimación engañosamente optimista (*optimism bias*) producto del **sobreajuste (*overfitting*)**. El estimador memoriza las correlaciones espurias y el ruido muestral en lugar de capturar la distribución poblacional verdadera, perdiendo su capacidad de generalización sobre clientes futuros no vistos.

2 Sección B: Auditoría Exploratoria y Diagnóstico de Calidad

El conjunto de datos crudo (`clientes_financieros_examen.csv`) cuenta inicialmente con **6.035 registros y 13 atributos**.

2.1 Valores Faltantes y Coerción de Tipos

Se identificó una severa anomalía tipográfica: las variables `edad`, `ingresos_anuales` y `saldo_promedio` fueron catalogadas como `object` (texto) por la presencia de cadenas espurias `"desconocido"`.

Variable	Tipo Inicial	Nulos Explícitos	Porcentaje (%)	Strings 'desconocido'
`ingresos_anuales`	`object`	362	6.00 %	12
`saldo_promedio`	`object`	299	4.95 %	12
`estado_civil`	`object`	239	3.96 %	0
`canal`	`object`	180	2.98 %	0
`edad`	`object`	152	2.52 %	12
`region`	`object`	120	1.99 %	25 (marcados como '?')

Tabla 1: Diagnóstico inicial de valores faltantes y marcadores espurios.

2.2 Duplicados y Distribución del Target

- **Duplicados Exactos:** Se confirmaron **35 registros duplicados idénticos** tanto en su identificador `id_cliente` como en todos sus atributos clínicos y financieros.

- **Distribución de la Variable Objetivo:** La clase 0 (permanencia) registra **5.216 observaciones (86,43 %)**, mientras que la clase 1 (abandono) cuenta con **819 observaciones (13,57 %)**, arrojando un ratio de desbalance moderado de **6,37 a 1**.

2.3 Interpretación de Tres Hallazgos Críticos

1. **Hallazgo 1: Tipos erróneos, centinelas y edades imposibles:** La presencia de strings impide operaciones algebraicas. Asimismo, se identificaron edades de hasta 250 años y saldos con centinela `-999999.00` (10 registros). Ambos deben mapearse a `NaN` para su posterior imputación, conservando los sobregiros legítimos ($saldo < 0$).

2. **Hallazgo 2: Fuga de información en `motivo_baja`:** El 100 % de los clientes que no abandonan tienen `"No aplica"`, y el 100 % de los que abandonan tienen una causal explícita. Al ser un atributo post-evento, causaría un atajo trivial y engañoso. Se excluye totalmente de X.

3. **Hallazgo 3: Redundancia y categorías fragmentadas:** Se unificaron variantes de strings con espacios en blanco (`"DIGITAL"`, `"SUCURSAL"`), capitalización y símbolos ¿", y se removieron los 35 duplicados exactos.

3 Sección C: Saneamiento de Datos y Reglas de Dominio

A partir de `df_raw`, se generó la base de datos saneada `df_clean` (6.000 registros):

- **Coerción Numérica:** Conversión de `edad`, `ingresos_anuales` y `saldo_promedio` con `pd.to_numeric(errors='coerce')`.
- **Normalización Categórica:** Eliminación de espacios marginales (`.str.strip()`), capitalización homogénea (`.str.capitalize()`) y mapeo de marcadores como `'?'` a `np.nan`.
- **Eliminación de Duplicados:** Se descartaron 35 filas redundantes, consolidando 6.000 clientes únicos.
- **Reglas de Dominio Financiero:** 1) Edades fuera del rango biológico $[18, 100]$ se convirtieron a `np.nan` (15 casos con > 100 años). 2) Centinelas de error transaccional `saldo_promedio == -999999` se sustituyeron por `np.nan` (10 casos). 3) Los sobregiros legítimos ($saldo < 0$, 548 clientes) se preservaron intactos, reconociendo su valor semántico como indicador de vulnerabilidad financiera.

4 Sección D: Preparación de Características y Diseño Experimental

4.1 Definición de Matrices y Prevención de Fuga

Se descartó el identificador arbitrario `id_cliente` y la variable post-evento `motivo_baja`, asegurando que la matriz de características X contenga únicamente 10 predictores observables en tiempo de inferencia:

$$X = [\text{edad}, \text{ingresos_anuales}, \text{antiguedad_meses}, \text{saldo_promedio}, \text{productos_activos}, \text{canal}, \text{estado_civil}, \text{region}, \text{contacto_preferido}, \text{incumplimiento}] \quad (2)$$

4.2 Partición Estratificada 80/20

Se ejecutó una división *Hold-out* preservando exactamente la proporción de la variable objetivo mediante `train_test_split` con `stratify=y` y `random_state=42`:

- **Conjunto de Entrenamiento (X_{train}):** 4.800 registros (86,44 % permanencia, 13,56 % abandono).
- **Conjunto de Prueba (X_{test}):** 1.200 registros (86,42 % permanencia, 13,58 % abandono).

4.3 Arquitectura del ColumnTransformer

Para prevenir de forma absoluta la fuga de datos, el preprocesamiento se encapsuló en un `ColumnTransformer` ajustado (`fit`) exclusivamente sobre X_{train}:

- **Sub-pipeline Numérico:** Imputación por mediana (`SimpleImputer(strategy='median')`) seguida de estandarización normal (`StandardScaler()`).
- **Sub-pipeline Categórico:** Imputación por la moda (`SimpleImputer(strategy='most_freque`) seguida de codificación binaria One-Hot (`OneHotEncoder(handle_unknown='ignore')`).

Verificación de Integridad Matemática en Matrices Finales:

- Dimensiones transformadas: $X_{train} \in \mathbb{R}^{4800\times19}$, $X_{test} \in \mathbb{R}^{1200\times19}$.
- Total de características generadas: 5 numéricas estandarizadas + 14 columnas dummy OHE.
- Verificación de nulos residuales: NaNs en Train $= 0$, NaNs en Test $= 0$.
- Verificación de infinitos: Infinitos en Train $= 0$, Infinitos en Test $= 0$.

Figura 1: Resultados cuantitativos del procesamiento en Scikit-Learn.

5 Sección E: Diseño Experimental, Ética y Conclusiones

5.1 Análisis de Sesgo en la Eliminación de Outliers

La poda mecánica de valores atípicos reduce la varianza y la representatividad muestral. En el dominio financiero, los comportamientos extremos (ej. saldos sobregirados o patrimonios atípicos) representan precisamente los escenarios de mayor criticidad para la deserción. Ignorarlos generaría modelos sesgados hacia el cliente promedio e incapaces de generalizar ante casos de estrés económico.

5.2 Justificación del Ajuste Estricto en Entrenamiento

Ajustar los estimadores de imputación y escalamiento $(\tilde{x}, \mu, \sigma)$ únicamente en X_{train} garantiza la independencia estadística de X_{test}. Si se utilizara el dataset completo, los parámetros del conjunto de prueba contaminarían el entrenamiento, provocando una falsa sensación de alto rendimiento que fracasará en el despliegue real.

5.3 Mecanismo de Fuga en Variables Post-Evento

La variable `motivo_baja` constituye un atajo espurio (*shortcut learning*). Al existir únicamente tras la decisión de baja, su inclusión obligaría al modelo a depender de una característica inexistente en clientes activos, invalidando su función predictiva.

5.4 Riesgos Éticos y Gobernanza de Datos

1. **Discriminación Indirecta (*Redlining*):** El uso de combinaciones entre `region` y `estado_civil` puede correlacionar con clases socioeconómicas protegidas, penalizando sistemáticamente a clientes de ciertas zonas.
2. **Privacidad y Consentimiento:** El uso de historiales crediticios requiere autorización explícita y gobernanza conforme al marco de protección de datos personales.

5.5 Controles de Calidad y Equidad Propuestos

Se propone auditar la paridad estadística mediante métricas de equidad (*Disparate Impact Ratio*, *Equalized Odds*), incorporar explicabilidad mediante valores SHAP (*Human-in-the-loop*) y supervisar continuamente la deriva de datos (*Data Drift*) en producción.

5.6 Conclusión y Dictamen Técnico

Los datos se encuentran **100 % acondicionados, validados y libres de fugas** para proceder con la fase de modelado predictivo. Como limitación persistente, se destaca el desbalance de clases (13,6 % abandono), el cual requerirá utilizar métricas no sensibles al sesgo mayoritario (PR-AUC, F1-Score) y algoritmos con ponderación de costos (`class_weight='balanced'`).